

1. How many examples are there in the dataset?

```
Number of examples (rows): 2494  
Number of features (columns): 28
```

2. What is the distribution of the target?

La distribution est East North Central (758), West North Central (358), Middle Atlantic (334), South Atlantic (248), Pacific (243), Mountain (190), West South Central (172), East South Central (97) et New England (94) répondants. Cette distribution est déséquilibrée car la région East North Central a beaucoup plus d'exemples que les régions comme New England ou East South Central.

3. What are the features that can be used to predict the target?

Il y a 1 variable réellement numérique (RespondentID) et 27 variables catégorielles .

4. Are there any missing values in the dataset?

Il n'y a aucune valeur NaN dans le jeu de données, mais certaines réponses sont encodées par le caractère '?' dans les colonnes Household_Income et Education, ce qui correspond probablement à des données manquantes ou inconnues qu'il faudrait traiter comme des valeurs manquantes.

5. What is the most common answer to "How much do you personally identify as a Midwesterner"?

Not at all: 965

A lot: 697

Some: 528

Not much: 304

Question 6: Among the three models, which one has the best recall?

Parmi les trois modèles, celui qui a le meilleur rappel pour la classe positive "North Central" est Gradient Boosting . Cela signifie qu'il retrouve la plus grande proportion de vrais exemples "North Central"

Question 7: Which model has the best practical application?

Avec la fonction de coût donnée, le modèle ayant la meilleure application pratique est Gradient Boosting, car il obtient le score pratique le plus élevé (4629), donc il maximise les prédictions utiles tout en limitant les erreurs coûteuses.

Question 8: Which model generalizes the best?

Le modèle qui généralise le mieux est Random Forest son accuracy de test 0.944 est proche de son accuracy moyenne en validation croisée 0.935 avec un écart raisonnable entre train et test ce qui indique une bonne capacité de généralisation.

Le modèle qui sur apprend le plus est Gradient Boosting il a une accuracy de 1.00 sur l'entraînement mais une accuracy de test légèrement plus basse 0.977 et surtout une moyenne de cross-validation plus faible 0.921 ce qui montre un sur apprentissage plus marqué même si ses performances restent très bonnes.



